

以「站層 bootstrap」量化門檻超標 Brier 分數比較的不確定性

方法說明 (配 brier_bootstrap.R)

2026 年 7 月

Abstract

論文以樣本外 Brier 分數排名候選模型，但表格中 Rank 1-4 常讀到相同的 0.030，也就是名次落在第四位小數以後、埋在雜訊裡。本文說明：(一) 要量化的不是單一 Brier，而是兩模型的**配對差** $\Delta = \text{BS}_A - \text{BS}_B$ ；(二) 它的不確定性有三個來源，主力是「哪些站落入驗證集」；(三) 為什麼比較必須先**配對**再算變異；(四) 用**站層 (cluster) bootstrap** 給 Δ 一條信賴區間與檢定 p 值。最後把方法套在臭氧 200/200 split 的兩個配對比較上，用真實數字說明結論：加了不確定性之後，AR(2) 與 MRTS 兩項延伸在整條上尾都無法與其配對基準區分。

1 問題：名次落在雜訊裡

評分程式 autoselect.R 用 *pooled* Brier 排名，把所有驗證「站 $\times$ 日」壓成一個數：

$$\overline{\text{BS}}_A = \frac{1}{N} \sum_{i=1}^N b_i^A, \quad b_i^A = (I(y_i > L) - \hat{P}_A(Y_i > L))^2, \quad (1)$$

其中 i 跑遍驗證的 (站, 日)， L 是超標門檻， $\hat{P}_A$ 是模型 A 的後驗預測超標機率。問題在於： $\overline{\text{BS}}_A$ 只是一個估計值，它在估計一個母體量 (模型 A 對門檻 L 的期望 Brier)。換一批驗證站、換一組資料、換一段 MCMC，它就會抖動。若不報這個抖動的大小，就無從判斷 0.0305 與 0.0305 的名次是不是真的。

2 要量化的是「差」，不是各自的分數

論文的科學主張是「 A 比 B 好」，這是對差的主張。所以要量化的對象是

$$\Delta = \overline{\text{BS}}_A - \overline{\text{BS}}_B, \quad \Delta < 0 \iff A \text{ 較佳}. \quad (2)$$

不確定性有三個來源，務必分開看：

來源	什麼在隨機	通常大小
(a) 評估／測試集	哪些站、哪些日落入 held-out	最大宗
(b) 複製	抽到哪幾組資料 (模擬才有)	中
(c) 後驗 Monte Carlo	MCMC 抽樣讓 $\hat{P}$ 本身有誤差	通常最小

實證的主力是 (a)。至於 (c)：本例每個擬合保留 5000 個後驗抽樣。(後續實測修正，見 *folder 09*：用 batch-means 實測後，(c) 對 Brier / twCRPS 只佔評估不確定性的 19% / 26%——次要，null 不受影響；但對 **plain CRPS 高達 70%、不可忽略**。故先前「可忽略」的斷言對 CRPS 是錯的，這也是 CRPS 顯著格不可信的原因之一。 $\sqrt{p_i(1-p_i)/M}$ 的樸素公式低估了 CRPS 這種連續分數的 MC 誤差。)

3 關鍵觀念：先配對，再算變異

A 與 B 是在**同一批** held-out 觀測上評分，兩者分數高度正相關（某個站本來就難預測，兩模型的 b_i 會一起變大）。因此

$$\text{Var}(\Delta) = \text{Var}(\overline{\text{BS}}_A) + \text{Var}(\overline{\text{BS}}_B) - 2\text{Cov}(\overline{\text{BS}}_A, \overline{\text{BS}}_B), \quad (3)$$

其中 -2Cov 會把差的變異壓得遠小於兩邊際變異之和。實務後果：

- **錯**：給 A 一條 CI、給 B 一條 CI，看它們重不重疊。這丟掉了相關性，嚴重高估 Δ 的不確定性，讓你永遠測不出差異。
- **對**：先算**逐站差** $d_j = b_j^A - b_j^B$ ，再對它估不確定性。共同的「難易度」自動抵消。順序不能反。

4 站層 bootstrap：獨立單位是「站」

獨立單位。 空間 CV 裡，同一站不同日高度相關，鄰近站也相關。真正近似獨立、可重抽的單位是**驗證站**。因此我們對站有放回重抽，並把被抽中的站連同它所有日一起帶走 (block / cluster bootstrap)。

比值估計量。 pooled Brier (??) 是一個比值 $\sum_{\text{站}} \text{SSE} / \sum_{\text{站}} \text{天數}$ ，其中 $\text{SSE}_j = \sum_t (I - \hat{P})^2$ 是站 j 的平方誤差和、 n_j 是站 j 的非缺失天數。配對差寫成

$$\Delta = \frac{\sum_j (\text{SSE}_j^A - \text{SSE}_j^B)}{\sum_j n_j}. \quad (4)$$

演算法。 對 $b = 1, \dots, B$ (本文 $B = 2000$)：

1. 從 n_{site} 個站中有放回抽出同數量的站，得索引集 $\mathcal{I}_b$ ；
2. 只用 $\mathcal{I}_b$ 內的站重算 (??)，得 Δ_b^* 。

$\{\Delta_b^*\}$ 的 2.5%, 97.5% 分位數即 95% 信賴區間；雙尾 p 值取 $2 \min\{\Pr(\Delta^* \leq 0), \Pr(\Delta^* \geq 0)\}$ 。這正是 `brier_bootstrap.R` 中 `boot_pair()` 做的事，per-site 的 SSE 直接沿用既有的 `BrierScoreSite()`。

5 臭氧實例 (200/200 split)

我們挑**配對比較**：只差一個因素的兩個模型，讓每條 CI 直接回答「這個延伸有沒有用」。

- **AR(2) 效果**：setting 111 (skew- t , $K=7$, $T=50$, **AR2**) 對 setting 61 (同 K, T ，但 **AR1**)。
- **MRTS 效果**：setting 204 ($K=1$, $T=0$, TS, **MRTS**=10) 對 setting 51 (同設定，無 **MRTS**)。

表 ?? 的 Δ 與 CI 以 10^{-3} 為單位。 n_{exceed} 是該門檻背後**真正的超標事件數**。

Table 1: 配對 Brier 差 $\Delta = \text{BS}_A - \text{BS}_B$ (負 = A 較佳)，95% 站層 bootstrap CI ($B=2000$)。 Δ 、CI 以 10^{-3} 計。星號 = CI 不含 0。

比較	L 分位	BS_A	BS_B	Δ	95% CI	p	n_{exc}
AR(2) vs AR(1)	0.90	0.0505	0.0504	+0.099	$[-0.351, +0.544]$	0.661	630
	0.95	0.0305	0.0305	-0.062	$[-0.420, +0.288]$	0.753	319
	0.98	0.0151	0.0151	-0.089	$[-0.252, +0.085]$	0.310	129
	0.99	0.0078	0.0078	+0.024	$[-0.087, +0.176]$	0.777	56
	0.995	0.0043	0.0043	-0.034	$[-0.084, +0.023]$	0.245	27
MRTS vs none	0.90	0.0504	0.0505	-0.071	$[-0.479, +0.347]$	0.749	630
	0.95	0.0309	0.0310	-0.079	$[-0.341, +0.167]$	0.521	319
	0.98	0.0152	0.0153	-0.114	$[-0.252, +0.002]$	0.056	129
	0.99	0.0078	0.0079	-0.050	$[-0.122, +0.012]$	0.126	56
	0.995	0.0043	0.0043	-0.028	$[-0.057, -0.004]^*$	0.018	27

結論：差異埋在雜訊裡。 看數量級即可： Δ 約 10^{-4} ，而 CI 半寬約 $3-5 \times 10^{-4}$ ，差異比自身不確定性小一個數量級。除最後一列外，**每個 CI 都跨過 0**、 p 值落在 0.25–0.78。加了不確定性之後，AR(2) 五個 level 沒有一個顯著，MRTS 也只有一個邊界例外。這用數字證實了：把 0.030 對 0.030 排名次，是在讀雜訊。

唯一的星號是一堂反例課。 MRTS 在 $q = 0.995$ 的 CI 剛好不含 0 ($p = 0.018$)，但不應採信，理由有三，且恰好指向後續兩個問題：

1. **事件太稀疏**：此 level 只有 $n_{\text{exc}} = 27$ 個超標事件 (對比 0.90 有 630)。最不穩的 level 反而「顯著」，是稀疏事件的典型假象。
2. **多重比較**：本表做了 10 個比較， $\alpha = 0.05$ 下期望就有約 0.5 個假陽性；跳出來的偏偏是最極端門檻——教科書級的 multiplicity artifact。(這是「不確定性量化」之後必接的下一步：多重性校正。)
3. **效果量可忽略**： -2.8×10^{-5} 對上基準 4.3×10^{-3} ，相對差僅 0.7%，即便為真也無實務意義。

6 怎麼寫進論文

把「Rank 1–4 都是 0.030」的名次表，改為（或增列）配對 $\Delta \pm \text{CI}$ ，並在文中直接寫：「在所有 *tail level*，*AR(2)* 與 *MRTS* 相對於各自配對基準的 *Brier* 差異，其 95% 站層 *bootstrap* 信賴區間均涵蓋 0（唯一例外出現在最稀疏的 $q = 0.995$ ， $n = 27$ ，且在 10 個比較的多重性下不足採信）。」這一句把 null result 從弱點轉為有嚴謹推論支撐的發現。

可重用。 `brier_bootstrap.R`：換 `split` 設 `$env:US_ALL_VAL_RESULTS_DIR='fits-300-100'` 並改 `setup_file`；換對照改頂端 `pairs`；輸出存於 `output/us-all-auto/tables/brier_bootstrap_pa`