

# 以「站層 bootstrap」量化門檻超標 Brier 分數比較的不確定性

方法說明 (配 brier\_bootstrap.R)

2026 年 7 月

## Abstract

論文以樣本外 Brier 分數排名候選模型，但表格中 Rank 1-4 常讀到相同的 0.030，也就是名次落在第四位小數以後、埋在雜訊裡。本文說明：(一) 要量化的不是單一 Brier，而是兩模型的**配對差**  $\Delta = \text{BS}_A - \text{BS}_B$ ；(二) 它的不確定性有三個來源，主力是「哪些站落入驗證集」；(三) 為什麼比較必須先**配對**再算變異；(四) 用**站層 (cluster) bootstrap** 給  $\Delta$  一條信賴區間與檢定  $p$  值。最後把方法套在臭氧 200/200 split 的兩個配對比較上，用真實數字說明結論：加了不確定性之後，AR(2) 與 MRTS 兩項延伸在整條上尾都無法與其配對基準區分。

## 1 問題：名次落在雜訊裡

評程式 autoselect.R 用 *pooled* Brier 排名，把所有驗證「站  $\times$  日」壓成一個數：

$$\overline{\text{BS}}_A = \frac{1}{N} \sum_{i=1}^N b_i^A, \quad b_i^A = (I(y_i > L) - \hat{P}_A(Y_i > L))^2, \quad (1)$$

其中  $i$  跑遍驗證的 (站, 日)， $L$  是超標門檻， $\hat{P}_A$  是模型  $A$  的後驗預測超標機率。問題在於： $\overline{\text{BS}}_A$  只是一個估計值，它在估計一個母體量 (模型  $A$  對門檻  $L$  的期望 Brier)。換一批驗證站、換一組資料、換一段 MCMC，它就會抖動。若不報這個抖動的大小，就無從判斷 0.0305 與 0.0305 的名次是不是真的。

## 2 要量化的是「差」，不是各自的分數

論文的科學主張是「 $A$  比  $B$  好」，這是對差的主張。所以要量化的對象是

$$\Delta = \overline{\text{BS}}_A - \overline{\text{BS}}_B, \quad \Delta < 0 \iff A \text{ 較佳}. \quad (2)$$

不確定性有三個來源，務必分開看：

| 來源                 | 什麼在隨機                    | 通常大小        |
|--------------------|--------------------------|-------------|
| (a) 評估／測試集         | 哪些站、哪些日落入 held-out       | <b>最大宗</b>  |
| (b) 複製             | 抽到哪幾組資料 (模擬才有)           | <b>中</b>    |
| (c) 後驗 Monte Carlo | MCMC 抽樣讓 $\hat{P}$ 本身有誤差 | <b>通常最小</b> |

實證的主力是 (a)。至於 (c)：本例每個擬合都保留 5000 個後驗抽樣， $\hat{P}_i$  的 Monte Carlo 誤差約  $\sqrt{p_i(1-p_i)/5000}$ ，遠小於 (a)，可忽略。

### 3 關鍵觀念：先配對，再算變異

$A$  與  $B$  是在同一批 held-out 觀測上評分，兩者分數高度正相關（某個站本來就難預測，兩模型的  $b_i$  會一起變大）。因此

$$\text{Var}(\Delta) = \text{Var}(\overline{\text{BS}}_A) + \text{Var}(\overline{\text{BS}}_B) - 2\text{Cov}(\overline{\text{BS}}_A, \overline{\text{BS}}_B), \quad (3)$$

其中  $-2\text{Cov}$  會把差的變異壓得遠小於兩邊際變異之和。實務後果：

- **錯**：給  $A$  一條 CI、給  $B$  一條 CI，看它們重不重疊。這丟掉了相關性，嚴重高估  $\Delta$  的不確定性，讓你永遠測不出差異。
- **對**：先算逐站差  $d_j = b_j^A - b_j^B$ ，再對它估不確定性。共同的「難易度」自動抵消。順序不能反。

### 4 站層 bootstrap：獨立單位是「站」

**獨立單位。** 空間 CV 裡，同一站不同日高度相關，鄰近站也相關。真正近似獨立、可重抽的單位是驗證站。因此我們對站有放回重抽，並把被抽中的站連同它所有日一起帶走 (block / cluster bootstrap)。

**比值估計量。** pooled Brier (1) 是一個比值  $\sum_{\text{站}} \text{SSE} / \sum_{\text{站}} \text{天數}$ ，其中  $\text{SSE}_j = \sum_t (I - \hat{P})^2$  是站  $j$  的平方誤差和、 $n_j$  是站  $j$  的非缺失天數。配對差寫成

$$\Delta = \frac{\sum_j (\text{SSE}_j^A - \text{SSE}_j^B)}{\sum_j n_j}. \quad (4)$$

**演算法。** 對  $b = 1, \dots, B$  (本文  $B = 2000$ )：

1. 從  $n_{\text{site}}$  個站中有放回抽出同數量的站，得索引集  $\mathcal{I}_b$ ；
2. 只用  $\mathcal{I}_b$  內的站重算 (4)，得  $\Delta_b^*$ 。

$\{\Delta_b^*\}$  的 2.5%, 97.5% 分位數即 95% 信賴區間；雙尾  $p$  值取  $2\min\{\Pr(\Delta^* \leq 0), \Pr(\Delta^* \geq 0)\}$ 。這正是 brier\_bootstrap.R 中 boot\_pair() 做的事，per-site 的 SSE 直接沿用既有的 BrierScoreSite()。

### 5 臭氧實例 (200/200 split)

我們挑**配對比較**：只差一個因素的兩個模型，讓每條 CI 直接回答「這個延伸有沒有用」。

- **AR(2) 效果**：setting 111 (skew- $t$ ,  $K=7$ ,  $T=50$ , **AR2**) 對 setting 61 (同  $K, T$ , 但 **AR1**)。
- **MRTS 效果**：setting 204 ( $K=1$ ,  $T=0$ , TS, **MRTS**=10) 對 setting 51 (同設定，無 **MRTS**)。

表 1 的  $\Delta$  與 CI 以  $10^{-3}$  為單位。 $n_{\text{exceed}}$  是該門檻背後真正的超標事件數。

Table 1: 配對 Brier 差  $\Delta = BS_A - BS_B$  (負 =  $A$  較佳)，95% 站層 bootstrap CI ( $B=2000$ )。 $\Delta$ 、CI 以  $10^{-3}$  計。星號 = CI 不含 0。

| 比較             | $L$ 分位 | $BS_A$ | $BS_B$ | $\Delta$ | 95% CI               | $p$   | $n_{\text{exc}}$ |
|----------------|--------|--------|--------|----------|----------------------|-------|------------------|
| AR(2) vs AR(1) | 0.90   | 0.0505 | 0.0504 | +0.099   | $[-0.351, +0.544]$   | 0.661 | 630              |
|                | 0.95   | 0.0305 | 0.0305 | -0.062   | $[-0.420, +0.288]$   | 0.753 | 319              |
|                | 0.98   | 0.0151 | 0.0151 | -0.089   | $[-0.252, +0.085]$   | 0.310 | 129              |
|                | 0.99   | 0.0078 | 0.0078 | +0.024   | $[-0.087, +0.176]$   | 0.777 | 56               |
|                | 0.995  | 0.0043 | 0.0043 | -0.034   | $[-0.084, +0.023]$   | 0.245 | 27               |
| MRTS vs none   | 0.90   | 0.0504 | 0.0505 | -0.071   | $[-0.479, +0.347]$   | 0.749 | 630              |
|                | 0.95   | 0.0309 | 0.0310 | -0.079   | $[-0.341, +0.167]$   | 0.521 | 319              |
|                | 0.98   | 0.0152 | 0.0153 | -0.114   | $[-0.252, +0.002]$   | 0.056 | 129              |
|                | 0.99   | 0.0078 | 0.0079 | -0.050   | $[-0.122, +0.012]$   | 0.126 | 56               |
|                | 0.995  | 0.0043 | 0.0043 | -0.028   | $[-0.057, -0.004]^*$ | 0.018 | 27               |

**結論：差異埋在雜訊裡。** 看數量級即可： $\Delta$  約  $10^{-4}$ ，而 CI 半寬約  $3-5 \times 10^{-4}$ ，差異比自身不確定性小一個數量級。除最後一列外，**每個 CI 都跨過 0**、 $p$  值落在 0.25–0.78。加了不確定性之後，AR(2) 五個 level 沒有一個顯著，MRTS 也只有一個邊界例外。這用數字證實了：把 0.030 對 0.030 排名次，是在讀雜訊。

**唯一的星號是一堂反例課。** MRTS 在  $q = 0.995$  的 CI 剛好不含 0 ( $p = 0.018$ )，但不應採信，理由有三，且恰好指向後續兩個問題：

1. **事件太稀疏**：此 level 只有  $n_{\text{exc}} = 27$  個超標事件 (對比 0.90 有 630)。最不穩的 level 反而「顯著」，是稀疏事件的典型假象。
2. **多重比較**：本表做了 10 個比較， $\alpha = 0.05$  下期望就有約 0.5 個假陽性；跳出來的偏偏是最極端門檻——教科書級的 multiplicity artifact。(這是「不確定性量化」之後必接的下一步：多重性校正。)
3. **效果量可忽略**： $-2.8 \times 10^{-5}$  對上基準  $4.3 \times 10^{-3}$ ，相對差僅 0.7%，即便為真也無實務意義。

## 6 怎麼寫進論文

把「Rank 1–4 都是 0.030」的名次表，改為 (或增列) 配對  $\Delta \pm \text{CI}$ ，並在文中直接寫：「在所有 tail level，AR(2) 與 MRTS 相對於各自配對基準的 Brier 差異，其 95% 站層 bootstrap

信賴區間均涵蓋 0 (唯一例外出現在最稀疏的  $q = 0.995$ ,  $n = 27$ , 且在 10 個比較的多重性下不足採信)。」這一句把 null result 從弱點轉為有嚴謹推論支撐的發現。

可重用。 brier\_bootstrap.R: 換 split 設 `$env:US_ALL_VAL_RESULTS_DIR='fits-300-100'` 並改 `setup_file`; 換對照改頂端 `pairs`; 輸出存於 `output/us-all-auto/tables/brier_bootstrap_pa`