

時間外推的不確定性：time-block forecast 配對檢定

方法 2（複製層），並揭示 Brier 對 CRPS 的檢定力落差

2026 年 7 月

為什麼這個 arm 最該補檢定

time-block forecast arm 是整個研究裡 AR(2) 唯一出現方向性增益的地方（論文 Table 4：ARFIMA 設定下 AR(2) 相對 iid 於 leads 1–5 約 12%）。論文自己也寫「none of the paired Brier differences reaches statistical significance」。本文把這句話量化，並揭示一個更深的問題：論文選的指標（單門檻 Brier）對它想偵測的訊號檢定力最弱。（但請一併讀 § 發現 3 與 folder 07 的修正：plain CRPS 確有訊號，卻是 bulk 效應；檢定力更高的尾部分數 twCRPS 同樣測不到，故此增益對超標目標並不成立。）

方法與前幾份一致：10 組乾淨資料是獨立複製，對每組取 lead-window 平均分數，逐組相減，做配對 t (95% CI) 與單尾 Wilcoxon (H_1 ：時間模型較佳)。數字由 `timeblock_paired_export.R` (Brier，讀 `blk1_brier_cache.RData`) 與 `timeblock_crps_export.R` (CRPS，重算 fits) 產生，且與既有 `analyze_threeway.R` 逐格吻合。

兩個發現

1. Brier 上一切不顯著。三個對照、兩個設定、兩個窗，95% CI 全部涵蓋 0，單尾 Wilcoxon p 值介於 0.13–0.87。即使是 ARFIMA、leads 1–5、AR(2)–iid 的 -6.8×10^{-3} （表面上的 12%）也帶著 $[-33, +20] \times 10^{-3}$ 的巨大 CI， $p_W = 0.70$ 。也就是說：那個「12%」是被少數資料組的大增益拉出來的平均，其中位數方向並不一致——這比「不顯著」更精確地說明了論文為何只能寫「directional」。

2. plain CRPS 上有訊號浮現。同樣的 fits、同樣的資料組，改用 plain CRPS（評分整個預測分布，而非單一門檻的二元事件）後，AR(2) 的增益在近單位根設定下達到（邊界）顯著。 q_{95} Brier 把每個預測壓成一個罕見二元事件、變異極大、檢定力極低；plain CRPS 用上整條預測分布，每個預測攜帶的資訊多得多。

3.（後續修正，見 folder 07）但那個增益在 bulk，不在尾部。把 CRPS 限制到尾部帶（twCRPS， $\int_{q_{.90}}^{q_{.99}} BS(z) dz$ ，檢定力遠高於單門檻 Brier）後，AR(2) 的增益掉回 $\Delta \approx 0$ ($p_W \approx 0.46$)，與單門檻 Brier 一致。也就是說，plain CRPS 偵測到的是分布主體（未來日的水準）改善，不是門檻超標的改善。所以更正的結論是：Brier 的 null 並非「尺太鈍」，

Table 1: Time-block forecast arm: paired differences over the 10 clean data sets, temporal model minus reference (negative favours the temporal model), with 95% paired- t CIs. Brier at q_{95} in units of 10^{-3} ; CRPS in native units. Stars mark a one-sided Wilcoxon $p < 0.05$ (H_1 : temporal model better). The AR(2) gain is invisible on single-threshold Brier but reaches (marginal) significance on CRPS, whose whole-distribution scoring carries far more information per forecast.

Design	Leads	Brier $_{q_{95}} \times 10^3$ [CI]	CRPS [CI]
<i>AR(2) – iid (does memory help?)</i>			
near-unit-root	1-5	−0.73 [−7.70, +6.24]	−0.80* [−1.72, +0.11]
	1-15	−0.34 [−4.37, +3.70]	−0.44* [−1.09, +0.20]
ARFIMA $d=0.45$	1-5	−6.84 [−33.24, +19.57]	−0.36 [−0.77, +0.05]
	1-15	−4.06 [−27.11, +18.98]	−0.08 [−0.39, +0.22]
<i>AR(2) – AR(1) (value of 2nd lag)</i>			
near-unit-root	1-5	−0.14 [−6.63, +6.35]	−0.66* [−1.53, +0.21]
	1-15	−1.99 [−6.37, +2.40]	−0.40* [−1.03, +0.23]
ARFIMA $d=0.45$	1-5	−3.01 [−16.32, +10.30]	−0.10 [−0.26, +0.05]
	1-15	−0.50 [−14.20, +13.19]	−0.05 [−0.36, +0.27]

而是真的——檢定力更高的尾部帶 twCRPS 同樣測不到。AR(2) 靠持續性改善的是 level，與本論文的超標目標無關。

對論文的建議

論文 persistence 小節目前是 Brier-only。建議：(1) 在該節並列 **plain CRPS 與尾部帶 twCRPS**，並據 folder 07 誠實陳述：plain CRPS 的 AR(2) 增益是 *bulk* 效應，兩個尾部分數 (Brier 與 twCRPS) 一律測不到，故對「門檻超標預測」這個目標 **不成立**；(2) 把 Table 4 換成本表格式 ($\Delta \pm \text{CI}$)，把「directional」改寫為引用 Table ?? 的區間與 p 值；(3) 加一句多重性提醒：共 12 個比較，邊界星號需保守解讀。這樣把 bulk-vs-tail 的分解講清楚，比單靠 Brier 或單靠 plain CRPS 的敘事都更精確、也更誠實。

資料：blk1_paired_ci.csv、blk1_paired_ci_crps.csv (code/analysis/time_block_forecast/block1_positive_con