

量化 CRPS 的不確定性：三個實驗的統一結果

plain CRPS + 站層 bootstrap / 複製層 Wilcoxon

2026 年 7 月

可以，而且和 Brier 是同一件事

「量化 CRPS 的不確定性」與「量化 Brier 的不確定性」是同一個問題：把每個預測化約成一個 per-unit 分數後，後面的重抽／配對檢定機器完全不變。換的只是分數算法。事實上兩者有精確關係

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} \underbrace{(F(L) - \mathbf{1}\{y \leq L\})^2}_{= \text{Brier}_L} dL,$$

你的門檻- L Brier 就是 CRPS 被積函數在 L 的值。CRPS 把它對所有門檻積分，所以每個預測攜帶的資訊更多、變異更小、檢定力更高。

三個 arm 的 CRPS 不確定性都算好了，用各自對口的獨立單位：臭氧用站層 bootstrap，模擬與 time-block 用 10 組資料的複製層配對檢定。

CRPS 揭露了 Brier 看不到的事

內插（臭氧、模擬空間 hold-out）：AR(2) 不只無益，在真實資料上甚至微幅有害。在 q_{95} Brier 上，臭氧的 AR(2)–AR(1) 差異 CI 涵蓋 0（測不出）。改用 CRPS 後，AR(2) 相對 AR(1) 的 CRPS 顯著較差，且在 200/200 與 300/100 兩個 split 都成立（ $p \approx 0.03$ ）。效果雖小（CRPS ≈ 5 ppb，差 0.02–0.04），但方向一致、可複現：多加第二階輕微拖累整條預測分布。MRTS 則在 CRPS 上仍與基準無法區分。（兩點修正，見 folder 06/07/08：此「較差」既屬 bulk 效應——尾部的 Brier 與 twCRPS 皆 ns；又對站間空間相依不穩健——空間 block bootstrap 下 p 由 0.03 升到 0.08–0.11、CI 含 0。故無論對口與否或統計穩健與否，它都不承載結論。）

外推（time-block forecast）：plain CRPS 較佳，但（修正後）是 bulk。同一個模型換到向前預測的任務，AR(2) 相對 iid 與 AR(1) 的 plain CRPS 改善在近單位根設定下達（單尾）顯著（ $p_w \approx 0.03$ ）。但 folder 07 的尾部帶 twCRPS 顯示此增益同樣在 bulk：一約束到尾部， Δ 掉回 ≈ 0 （ $p_w \approx 0.46$ ），與單門檻 Brier 一致。AR(2) 改善的是未來日的水準，不是超標機率。

Table 1: CRPS-difference uncertainty across the three arms (whole- distribution proper score; $\Delta = \text{CRPS}_{\text{first}} - \text{CRPS}_{\text{second}}$, negative favours the temporal/extension model). Ozone uses a 95% site-clustered bootstrap CI (p two-sided); simulation and time-block use a 95% paired- t CI over the 10 data sets (p_W one-sided Wilcoxon, H_1 : temporal better). The reading follows each row's own test at $\alpha = 0.05$; the two-sided time-block CIs graze 0 even where the one-sided p_W is significant. CRPS reveals what q_{95} Brier could not: AR(2) is (mildly) *worse* for real-data interpolation yet *better* for time-block extrapolation.

Arm	Contrast	Δ CRPS [95% CI]	p	reading
<i>Interpolation — spatial hold-out</i>				
Ozone 200/200	AR(2) – AR(1)	+0.021 [+0.003, +0.04]	$p=0.026$	worse
Ozone 200/200	MRTS – none	–0.017 [–0.053, +0.019]	$p=0.344$	ns
Ozone 300/100	AR(2) – AR(1)	+0.039 [+0.0037, +0.072]	$p=0.027$	worse
Sim K=1 strong	AR(2) – AR(1)	–0.000083 [–0.00052, +0.00036]	$p_W=0.342$	ns
Sim K=1 weak	AR(2) – AR(1)	–0.00000097 [–0.00023, +0.00022]	$p_W=0.581$	ns
Sim K=5 strong	AR(2) – AR(1)	+0.00052 [–0.0069, +0.0079]	$p_W=0.581$	ns
Sim K=5 weak	AR(2) – AR(1)	–0.0039 [–0.013, +0.0052]	$p_W=0.270$	ns
<i>Extrapolation — time-block forecast</i>				
Near-unit-root (1–5)	AR(2) – iid	–0.8 [–1.7, +0.11]	$p_W=0.026$	better
Near-unit-root (1–5)	AR(2) – AR(1)	–0.66 [–1.5, +0.21]	$p_W=0.033$	better

合起來（修正後）：尾部一律測不到。 folder 06/07 用尾部帶 twCRPS 把兩邊的 plain-CRPS 訊號都打回 bulk。用論文真正在乎的尾部分數（單門檻 Brier 與檢定力更高的 twCRPS）衡量：

內插：尾部 ns 且 外推：尾部 ns.

也就是說，AR(2) 在所有情境都不改變門檻超標的預測技巧；plain CRPS 的差異（臭氧較差、time-block 較佳）都是分布主體（level）效應，與超標目標無關。這比原本「AR(2) 是外推工具」的敘述更保守，卻由兩個尾部分數、跨三個 arm 一致支撐，證據力更強。

兩點但書

1. **plain CRPS vs threshold-weighted CRPS**。臭氧模型是 censored（只配尾部）。plain CRPS 對整條分布等權、故被 bulk 主導；對齊「超標預測」目標的是 twCRPS $= \int \text{Brier}_L w(L) dL$ （尾部加權）。folder 06/07 已建好 twCRPS 並以它做出上述 bulk-vs-tail 修正；量化方式與 plain CRPS 完全相同，只換權重 $w(L)$ 。
2. **多重性**。跨 arm 已累積數個邊界星號；正式寫入論文時應做多重比較校正（審查 #2），對最極端／最稀疏的顯著格保守解讀。

程式：ozone/US-all-auto/crps_bootstrap.R、simstudy/ar2_crps_export.R、block1_positive_control/timeblock_