

量化 CRPS 的不確定性：三個實驗的統一結果

plain CRPS + 站層 bootstrap / 複製層 Wilcoxon

2026 年 7 月

可以，而且和 Brier 是同一件事

「量化 CRPS 的不確定性」與「量化 Brier 的不確定性」是**同一個問題**：把每個預測化約成一個 per-unit 分數後，後面的重抽／配對檢定機器完全不變。換的只是分數算法。事實上兩者有精確關係

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} \underbrace{(F(L) - \mathbf{1}\{y \leq L\})^2}_{= \text{Brier}_L} dL,$$

你的門檻- L Brier 就是 CRPS 被積函數在 L 的值。CRPS 把它對所有門檻積分，所以每個預測攜帶的資訊更多、變異更小、**檢定力更高**。

三個 arm 的 CRPS 不確定性都算好了，用各自對口的獨立單位：臭氧用**站層 bootstrap**，模擬與 time-block 用 10 組資料的**複製層配對檢定**。

CRPS 揭露了 Brier 看不到的事

內插（臭氧、模擬空間 hold-out）：AR(2) 不只無益，在真實資料上甚至微幅有害。在 q_{95} Brier 上，臭氧的 AR(2)–AR(1) 差異 CI 涵蓋 0（測不出）。改用 CRPS 後，AR(2) 相對 AR(1) 的 CRPS **顯著較差**，且在 200/200 與 300/100 兩個 split 都成立（ $p \approx 0.03$ ）。效果雖小（CRPS ≈ 5 ppb，差 0.02–0.04），但方向一致、可複現：在真實資料的空間內插裡，多加第二階只是增添估計雜訊，輕微拖累整條預測分布。MRTS 則在 CRPS 上仍與基準無法區分。

外推（time-block forecast）：AR(2) **顯著較佳**。同一個模型，換到需要向前預測的任務，AR(2) 相對 iid 與相對 AR(1) 的 CRPS 改善在近單位根設定下達（單尾）顯著（ $p_W \approx 0.03$ ）。

合起來，是論文核心論點的最強版本。CRPS 的額外檢定力把「內插 vs 外推」的對比推到顯著：

內插：AR(2) 較差／持平 $\iff$ 外推：AR(2) 較佳。

這比原本「AR(2) 是預測工具、非內插工具」的敘述更決斷——而且只有在用了比 Brier 更有力的 CRPS 之後才浮現。

Table 1: CRPS-difference uncertainty across the three arms (whole- distribution proper score; $\Delta = \text{CRPS}_{\text{first}} - \text{CRPS}_{\text{second}}$, negative favours the temporal/extension model). Ozone uses a 95% site-clustered bootstrap CI (p two-sided); simulation and time-block use a 95% paired- t CI over the 10 data sets (p_W one-sided Wilcoxon, H_1 : temporal better). The reading follows each row's own test at $\alpha = 0.05$; the two-sided time-block CIs graze 0 even where the one-sided p_W is significant. CRPS reveals what q_{95} Brier could not: AR(2) is (mildly) *worse* for real-data interpolation yet *better* for time-block extrapolation.

Arm	Contrast	Δ CRPS [95% CI]	p	reading
<i>Interpolation — spatial hold-out</i>				
Ozone 200/200	AR(2) – AR(1)	+0.021 [+0.003, +0.04]	$p=0.026$	worse
Ozone 200/200	MRTS – none	–0.017 [–0.053, +0.019]	$p=0.344$	ns
Ozone 300/100	AR(2) – AR(1)	+0.039 [+0.0037, +0.072]	$p=0.027$	worse
Sim K=1 strong	AR(2) – AR(1)	–0.000083 [–0.00052, +0.00036]	$p_W=0.342$	ns
Sim K=1 weak	AR(2) – AR(1)	–0.00000097 [–0.00023, +0.00022]	$p_W=0.581$	ns
Sim K=5 strong	AR(2) – AR(1)	+0.00052 [–0.0069, +0.0079]	$p_W=0.581$	ns
Sim K=5 weak	AR(2) – AR(1)	–0.0039 [–0.013, +0.0052]	$p_W=0.270$	ns
<i>Extrapolation — time-block forecast</i>				
Near-unit-root (1–5)	AR(2) – iid	–0.8 [–1.7, +0.11]	$p_W=0.026$	better
Near-unit-root (1–5)	AR(2) – AR(1)	–0.66 [–1.5, +0.21]	$p_W=0.033$	better

兩點但書

1. **plain CRPS vs threshold-weighted CRPS**。臭氧模型是 censored (只配尾部)。plain CRPS 對整條分布等權；若要完全對齊「超標預測」目標、也更貼合 censored 設定，應改用 $\text{twCRPS} = \int \text{Brier}_L w(L) dL$ (尾部加權)。不確定性量化方式完全相同，只換權重 $w(L)$ 。本文先用 plain CRPS 取其檢定力與跨 arm 一致性。
2. **多重性**。跨 arm 已累積數個邊界星號；正式寫入論文時應做多重比較校正 (審查 #2)，對最極端／最稀疏的顯著格保守解讀。

程式：ozone/US-all-auto/crps_bootstrap.R、simstudy/ar2_crps_export.R、block1_positive_control/timeblock_