

twCRPS 站哪邊？尾部帶裁決 plain CRPS 的「AR(2) 較差」

Brier $\rightarrow$ twCRPS $\rightarrow$ CRPS 光譜

2026 年 7 月

問題

臭氧內插上，AR(2) 相對 AR(1) 出現了一個張力：單門檻 Brier 測不出差異，但 plain CRPS 顯著較差。plain CRPS 評的是整條預測分布，所以「較差」可能只是 *bulk*（分布主體）的效應，未必落在超標預測在乎的尾部。twCRPS 正好能裁決，因為三個分數是同一個被積函數的不同讀法：

$$\underbrace{\text{BS}(L)}_{\text{一個門檻}} \rightarrow \underbrace{\text{twCRPS} = \int_{q_{.90}}^{q_{.995}} \text{BS}(z) dz}_{\text{尾部帶}} \rightarrow \underbrace{\text{CRPS} = \int_{-\infty}^{\infty} \text{BS}(z) dz}_{\text{整條 (bulk 主導)}}$$

Table 1: Ozone AR(2) vs. AR(1) (skew- t , $K=7$, $T=50$): the same contrast read by three scores on the Brier $\rightarrow$ twCRPS $\rightarrow$ CRPS spectrum, with 95% site-clustered bootstrap CIs. $\Delta = \text{score}_{AR(2)} - \text{score}_{AR(1)}$; Brier is dimensionless, twCRPS and CRPS in ppb. The apparent “AR(2) worse” of plain CRPS is a bulk effect: restricting the integral to the tail band (twCRPS) returns a powerful null, agreeing with single-threshold Brier.

Score	Weights	Δ [95% CI]	p	reading
<i>200/200 split</i>				
Brier $q_{0.95}$	one threshold	-0.000062 [-0.00042, +0.00029]	$p=0.753$	ns
twCRPS	tail band $[q_{.90}, q_{.995}]$	-0.00015 [-0.0047, +0.0043]	$p=0.981$	ns
CRPS	whole line (bulk)	+0.021 [+0.003, +0.04]	$p=0.026$	worse
<i>300/100 split</i>				
Brier $q_{0.95}$	one threshold	-0.000027 [-0.00033, +0.00032]	$p=0.808$	ns
twCRPS	tail band $[q_{.90}, q_{.995}]$	-0.00021 [-0.0044, +0.0047]	$p=0.868$	ns
CRPS	whole line (bulk)	+0.039 [+0.0037, +0.072]	$p=0.027$	worse

裁決：CRPS 的訊號住在 bulk，不在尾部

twCRPS 站在 Brier 那邊：兩個 split 的 Δ 都幾乎精確為 0 ($p = 0.98、0.87$)，CI 涵蓋 0。而且這不是「沒力氣測」——twCRPS 把整段尾部的資訊併起來，CI 半寬只有基準 twCRPS (≈ 0.57 ppb) 的約 0.8%，是一個有力的虛無。相對地，plain CRPS 在同樣的資料上顯著較差 ($+0.021 / +0.039$ ppb, $p \approx 0.03$)。

唯一能同時解釋這三格的說法是：AR(2) 只稍微弄糟了中央 (bulk) 預測分布，plain CRPS 因為被 bulk 主導而偵測到它；但在超標尾部，AR(2) 與 AR(1) 無法區分。換句話說，plain CRPS 的「AR(2) 較差」對本論文的目標（門檻超標預測）不相關。

三個收穫

1. twCRPS 不等於單門檻 Brier。它有更高的檢定力 (CI 更窄)，因為把整段尾部的超標資訊併起來，而不是押在單一門檻的少數事件上。
2. twCRPS 也不等於 plain CRPS。它對口目標 (尾部加權)，能把 bulk 效應濾掉。這正是它在本例裡與 plain CRPS 分道揚鑣的原因。
3. 對論文的結論：內插任務上，AR(2) 對尾部超標預測無益也無害——這個虛無由兩個尾部分數 (單門檻 Brier 與高檢定力的 twCRPS) 共同支撐，比單靠 Brier 強得多。

兩點後續修正 (folder 07/08)。其一，本頁把 plain-CRPS 的「AR(2) 較差」當作真實的 bulk 效應；folder 08 進一步顯示它連統計上都不穩健——空間 block bootstrap 下 p 由 0.03 升到 0.08–0.11、CI 含 0，故無論對口與否都不承載結論。其二，folder 07 把同樣的尾部檢驗補到 time-block，發現連外推的 AR(2) 增益也在 bulk；因此最終結論不是「AR(2) 是外推工具」，而是 AR(2) 在任何情境都不改變尾部超標技巧。

程式：ozone/US-all-auto/twcrps_bootstrap.R (尾部帶 $[q_{.90}, q_{.995}]$ 、 $G=41$ 網格梯形積分、站層 bootstrap)。資料：{brier,twcrps,crps}_bootstrap_pairs_{200-200,300-100}.csv。