

殘餘不確定性稽核：MC error、FDR、Wilcoxon 離散

清掉文獻檢視剩下的三條 (#2–#4)

2026 年 7 月

承接 folder 08，本文把文獻檢視剩下的三條稽核項一次清掉：實測後驗 Monte-Carlo 誤差（先前只斷言）、對多重性做正式 FDR 校正（先前用嘴巴帶過）、以及誠實面對 $n = 10$ Wilcoxon 的 p 值離散。

#2 後驗 Monte-Carlo 誤差：實測，不斷言

folder 01 曾斷言「 $\hat{P}$ 的 MC 誤差 $\approx \sqrt{p(1-p)/M}$ ，遠小於評估不確定性、可忽略」。用 batch-means（5000 抽樣切 10 批，批間 SD/ $\sqrt{G}$ 估全樣本 pooled 分數的 MC s.e.；兩鏈獨立故 $\text{MC_se}(\Delta) = \sqrt{\text{se}_A^2 + \text{se}_B^2}$ ）實測後：

Table 1: Posterior Monte-Carlo error of the paired difference Δ (batch-means, $G=10$ batches of 500 draws) against the site-bootstrap CI half-width, ozone AR(2) vs. AR(1), 200/200. The ratio is MC noise as a fraction of evaluation uncertainty. Negligible it is not for plain CRPS.

Score	Δ	MC s.e. (Δ)	boot. CI half-width	ratio
Brier $q_{.95}$	$-6.2e - 05$	$6.6e - 05$	0.00035	0.19
twCRPS (tail)	-0.00015	0.0012	0.0045	0.26
plain CRPS	0.021	0.013	0.019	0.70

斷言部分錯。對 Brier 與 twCRPS，MC 噪音只佔評估不確定性的 19%、26%——次要，合併後 CI 僅寬 2–3%，**null 不受影響**。但對 **plain CRPS**，**MC 噪音高達 70%**，完全不可忽略：合併兩項 $\sqrt{0.0185^2 + 0.013^2} \approx 0.023$ 已大於效果量 $|\Delta| = 0.021$ 。也就是說，光是評估 + MC 兩項就讓 CRPS 的「AR(2) 較差」不顯著——這是繼 twCRPS（bulk）與 block bootstrap（不耐空間相依）之後，打死那格的**第三個角度**。

#3 多重性：正式 FDR，不再用嘴巴帶過

把全分析所有配對比較的 p 值收成一個家族，套 Benjamini–Hochberg（BH）與對相依穩健的 Benjamini–Yekutieli（BY）：

Table 2: Benjamini–Hochberg (BH) and Benjamini–Yekutieli (BY) FDR correction over the whole family of $m = 117$ paired comparisons. 7 are nominally significant (raw $p < 0.05$); **0 survive** either correction. The nominally significant cells are shown; all are plain-CRPS or the sparsest-level Brier, and none clears FDR.

Arm	Comparison	raw p	p_{BH}	p_{BY}
ozone-200-200	MRTS(10) vs none (brier)	0.018	0.458	1.000
timeblock	set5 1-15 AR(2) - AR(1) (crps)	0.021	0.458	1.000
ozone-200-200	AR(2) vs AR(1) (crps)	0.026	0.458	1.000
timeblock	set5 1-5 AR(2) - iid (crps)	0.026	0.458	1.000
ozone-300-100	AR(2) vs AR(1) (crps)	0.027	0.458	1.000
timeblock	set5 1-5 AR(2) - AR(1) (crps)	0.033	0.458	1.000
timeblock	set5 1-15 AR(2) - iid (crps)	0.042	0.458	1.000

117 個比較中 7 個名目顯著，校正後 0 個存活（最小 raw $p = 0.018 \rightarrow p_{BH} = 0.458$ ）。那 7 格全是 plain-CRPS 或最稀疏門檻的 Brier——正是先前逐一質疑過的。手一揮的「多重性下不足採信」現在有形式化支撐：沒有任何一格通過 FDR 0.05。

#4 Wilcoxon $n = 10$ ：p 值是離散的，別假裝三位精度

模擬與 time-block 用 $n = 10$ 的 signed-rank，其 null 分布離散。可達的單尾 p 值在 (0.005, 0.10) 之間只有 11 個：

0.0068, 0.0098, 0.0137, 0.0186, **0.0244**, **0.0322**, **0.0420**, 0.0527, 0.0654, 0.0801, 0.0967,

最小可達 $p = 1/2^{10} = 0.000977$ 。我先前（常態近似）報的 0.026、0.033、0.042 其實只能落在 0.0244、0.0322、0.0420——報到小數三位是虛報精度，且這些「 < 0.05 」的格正卡在門檻附近的網格點上，本就脆弱。（此點不改變任何結論——經 #3 校正後它們本來就都不顯著——但誠實報告應註明 $n = 10$ 的離散性，或改用 exact test。）

總結：文獻檢視的每一條都已落地

- #1 站間相依 (folder 08)：null 全通過空間 block bootstrap；唯一顯著格瓦解。
- #2 MC 誤差：Brier/twCRPS 次要（null 無恙）；CRPS 達 70%，是打死那格的第三個角度。
- #3 多重性：正式 FDR 下 7 個名目顯著格全數不存活。
- #4 Wilcoxon 離散：報告精度已更正；不影響結論。

淨效果：論文核心結論（AR(2)/MRTS 在任何情境、任何尾部分數下都不改變門檻超標的預測技巧）是 **null**，通過了站間相依、MC 誤差、多重性三重加壓；而每一個曾經「顯著」的格，都在至少一個（多半是全部三個）角度下瓦解。整條不確定性分析至此經得起教科書等級的檢視。

程式：ozone/US-all-auto/mc_error_check.R、simstudy/fdr_correction.R。資料：mc_error_check.csv、fdr_correction.csv。